

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH



ĐỒ ÁN CUỐI KÌ MÔN MÁY HỌC (CS114)

**ĐỀ TÀI: SO SÁNH HAI MÔ HÌNH LOGISTIC REGRESSION
VÀ GAUSSIAN DISCRIMINANT ANALYSIS CHO BÀI TOÁN
PHÂN LOẠI ẢNH THẬT VÀ ẢNH ĐÃ QUA CHỈNH SỬA**

Mã lớp: CS114.Q21

Giảng viên hướng dẫn: TS. Võ Nguyễn Lê Duy
Danh sách sinh viên thực hiện (Nhóm 11):

Lý Hoài Phong	24521334
Lê Minh Phú	24521354
Nguyễn Bình Phú	24521356
Tăng Nguyễn Bảo Quỳnh	24521512
Nguyễn Trần Tài	24521556
Bùi Trọng Tấn	24521573

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

MỤC LỤC

1	Giới thiệu đề tài và bộ dữ liệu	1
1.1	Bài toán đặt ra	1
1.2	Mục tiêu nghiên cứu	1
1.3	Hướng tiếp cận	1
1.4	Giới thiệu bộ dữ liệu	1
2	Trích xuất đặc trưng và tiền xử lý dữ liệu	2
2.1	Thay đổi kích thước ảnh và trải phẳng vector	2
2.2	Feature Engineering với ELA (Error Level Analysis)	2
2.3	Feature Engineering với FFT (Fast Fourier Transform)	2
2.4	Feature Engineering với LBP (Local Binary Pattern)	3
2.5	YCbCr Color Space Features (Kênh Cb và Cr)	3
2.6	Trực giao hóa và giảm chiều với PCA	3
2.7	Chuẩn hóa bằng Standard Scaler	3
3	Mô hình và phương pháp	4
3.1	Mô hình phân loại	4
3.2	Tiêu chí đánh giá	4
4	Kết quả thực nghiệm	5
4.1	Kết quả huấn luyện	5
4.2	Ma trận nhầm lẫn	5
4.3	Kết quả đánh giá trên tập kiểm thử	6
4.4	Không gian phân bố dữ liệu và ranh giới quyết định	7
4.5	Đánh giá chung	7
5	Kết luận và hướng phát triển	8
5.1	Kết luận	8
5.2	Hạn chế	8
5.3	Hướng phát triển	8

Chapter 1

Giới thiệu đề tài và bộ dữ liệu

1.1 Bài toán đặt ra

Sự phát triển mạnh mẽ của các công cụ chỉnh sửa ảnh như **Adobe Photoshop**, **Affinity Photo** cùng nhiều phần mềm khác giúp việc chỉnh sửa ảnh ngày càng dễ dàng và chân thực hơn. Các thao tác như ghép cảnh hay thay đổi chi tiết nhận dạng có thể được thực hiện rất tinh vi, khiến mắt người khó phân biệt.

Điều này gây ra nhiều thách thức trong việc xác minh tính xác thực của hình ảnh, đặc biệt trong các lĩnh vực như truyền thông, báo chí và thương mại điện tử. Vì vậy, phát hiện và phân loại chính xác giữa ảnh thật và ảnh đã chỉnh sửa là một bài toán quan trọng trong thị giác máy tính và học máy.

1.2 Mục tiêu nghiên cứu

Mục tiêu của đề tài là so sánh hiệu quả của hai mô hình **Logistic Regression** và **Gaussian Discriminant Analysis** trong bài toán phân loại ảnh thật và ảnh đã chỉnh sửa. Kết quả được đánh giá thông qua các chỉ số như Accuracy, Precision, Recall, F_1 -score và ROC-AUC, từ đó xác định mô hình phù hợp hơn cho bài toán. Ngoài ra, nghiên cứu cũng phân tích ưu điểm, hạn chế của từng phương pháp và đề xuất hướng cải tiến trong tương lai.

1.3 Hướng tiếp cận

Đề tài sử dụng phương pháp học máy có giám sát trên tập dữ liệu gồm hai lớp ảnh thật và ảnh giả. Dữ liệu được tiền xử lý qua các bước chuẩn hóa pixel, trích xuất đặc trưng và giảm chiều bằng **Principal Component Analysis** nhằm giữ lại thông tin quan trọng và hạn chế nhiễu. Sau đó, hai mô hình được huấn luyện trên cùng điều kiện thực nghiệm để đảm bảo tính khách quan trong quá trình so sánh và đánh giá.

1.4 Giới thiệu bộ dữ liệu

Nhóm sử dụng bộ dữ liệu *Real & Fake Images Dataset – For Image Forensics*¹ bởi tác giả Shivam Ardeshtna. Được xây dựng nhằm hỗ trợ các mô hình nhận diện ảnh giả trong lĩnh vực image forensics. Bộ dữ liệu chia thành ba tập: **Train:** 40,002 ảnh, **Test:** 12,360 ảnh, **Validation:** 5,227 ảnh. Trong mỗi tập dữ liệu, số lượng ảnh thật và ảnh đã chỉnh sửa phân bổ cân bằng, hạn chế thiên lệch về một lớp khi huấn luyện.




Figure 1.1: Ví dụ về bộ dữ liệu

¹<https://www.kaggle.com/datasets/shivamardeshna/real-and-fake-images-dataset-for-image-forensics>

Chapter 2

Trích xuất đặc trưng và tiền xử lý dữ liệu

2.1 Thay đổi kích thước ảnh và trải phẳng vector

Toàn bộ ảnh đầu vào được chuyển về cùng một kích thước chuẩn là $128 \times 128 \times 3$ trong hệ RGB đảm bảo dữ liệu đầu vào có cùng số chiều đặc trưng.

Sau khi resize, giá trị pixel được chuẩn hóa về khoảng $[0, 1]$ bằng cách chia toàn bộ giá trị cho 255.0. Tiếp theo, ảnh được trải phẳng từ ma trận ba chiều sang vector một chiều, vector thu được có: $128 \times 128 \times 3 = 49,152$ đặc trưng.

2.2 Feature Engineering với ELA (Error Level Analysis)

Kỹ thuật **ELA** phát hiện dấu hiệu chỉnh sửa ảnh qua sai khác trong quá trình nén JPEG. Ảnh gốc được nén lại với chất lượng cố định với $quality = 90$, sau đó tính sai khác tuyệt đối: $ELA_map = |Original - Recompressed|$. Kết quả là bản đồ lỗi nén, các vùng có sai khác lớn là khu vực đã bị chỉnh sửa. Ảnh fake thường có giá trị lỗi nén trung bình cao hơn ảnh real, thể hiện rõ ở phần đuôi phân phối lệch phải.




Figure 2.1: Bản đồ lỗi nén của bộ dữ liệu

Từ ELA map, nhóm trích xuất 9 đặc trưng thống kê gồm giá trị trung bình, lớn nhất và độ lệch chuẩn trên ba kênh màu R, G, B cho vector đặc trưng đầu vào.

2.3 Feature Engineering với FFT (Fast Fourier Transform)

Chỉ số **FFT** giúp phân tích ảnh trong miền tần số phát hiện dấu hiệu bất thường ảnh giả để lại, đặc biệt ở vùng biên cắt ghép. Biên độ phổ được tính theo công thức: $Magnitude = \log(1 + |F(u, v)|)$. Phổ tần số chia thành 3 vành đồng tâm *low*, *mid*, *high*. Trên mỗi vành, nhóm chọn 3 đặc trưng *mean*, *std*, *max* tạo thành 9 features đầu vào.




Figure 2.2: Biểu đồ dải High-frequency trên tập dữ liệu huấn luyện

Dải high-frequency thể hiện sự khác biệt lớn giữa ảnh hai lớp, cho thấy khả năng hỗ trợ phân loại của đặc trưng FFT, ảnh REAL có giá trị khoảng 5.4 – 5.6, trong khi ảnh FAKE từ khoảng 6.0 – 6.2 do nhiều bất liên tục vì mô từ thao tác chỉnh sửa.

2.4 Feature Engineering với LBP (Local Binary Pattern)

Phương pháp **LBP** trích xuất đặc trưng texture từ đó xây dựng histogram chuẩn hóa gồm 10 bins, ứng với 10 features. Khác biệt rõ nhất nằm ở Bin 9, đại diện cho các mẫu *non-uniform*, nơi ảnh giả có giá trị cao do thao tác cắt ghép phá vỡ tính liên tục.




Figure 2.3: Biểu đồ chỉ số LBP trên tập dữ liệu huấn luyện

2.5 YCbCr Color Space Features (Kênh Cb và Cr)

Nhóm chuyển đổi ảnh từ RGB sang **YCbCr** và loại bỏ kênh **Y** (độ sáng), chỉ giữ lại hai kênh sắc độ **Cr** và **Cb**. Do các thao tác chỉnh sửa thường tái tạo kênh Y rất tốt, sự khác biệt chủ yếu xuất hiện ở lỗi màu sắc vi mô trong hai kênh chrominance.

Kết quả histogram cho thấy ảnh fake có xu hướng dư thừa sắc đỏ ở kênh **Cr** và thiếu chiều sâu sắc xanh ở kênh **Cb**. Vì vậy, vector đặc trưng gồm **32 bins Cr** + **32 bins Cb** có khả năng phân tách tốt cho bài toán phát hiện ảnh giả.




Figure 2.4: Biểu đồ phân phối trên không gian màu YCbCr của tập huấn luyện

2.6 Trực giao hóa và giảm chiều với PCA

Kĩ thuật **Principal Component Analysis (PCA)** giúp giảm chiều dữ liệu xuống một tập các thành phần chính mới không tương quan, nhưng đồng thời giữ lại phần lớn thông tin quan trọng. Qua đó, hạn chế nhiễu và cải thiện tốc độ huấn luyện của mô hình.

2.7 Chuẩn hóa bằng Standard Scaler

Để tránh các đặc trưng có giá trị lớn chi phối mô hình, **Standard Scaler** giúp đưa dữ liệu về phân phối chuẩn trung bình bằng 0 và độ lệch chuẩn bằng 1:

$$z = \frac{x - \mu}{\sigma}$$

Chapter 3

Mô hình và phương pháp

3.1 Mô hình phân loại

1. Logistic Regression: mô hình phân loại tuyến tính dựa trên xác suất, sử dụng hàm Sigmoid để ánh xạ đầu ra về khoảng $[0, 1]$. Tìm bộ tham số (w, b) tối ưu bằng cách tối thiểu hóa hàm mất mát *Binary Cross-Entropy* thông qua dự đoán xác suất $\hat{y}$ qua hàm *Sigmoid*:

$$J(w, b) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(\hat{y}^{(i)}) + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)}) \right]$$

Trong đó $\hat{y}^{(i)} = \sigma(w^T x^{(i)} + b) = 1 / (1 + \exp(-(w^T x^{(i)} + b)))$.

2. Gaussian Discriminant Analysis (GDA): mô hình phân loại sinh, giả định dữ liệu của mỗi lớp tuân theo phân phối Gaussian nhiều chiều. Từ đó, tối đa hóa hàm Log-likelihood đồng thời của đặc trưng và nhãn để xác định ranh giới phân quyết:

$$\ell(\phi, \mu_0, \mu_1, \Sigma) = \sum_{i=1}^m \left[\log p(x^{(i)} | y^{(i)}; \mu_0, \mu_1, \Sigma) + \log p(y^{(i)}; \phi) \right]$$

Với thành phần mật độ xác suất Gaussian đa biến của từng lớp được khai triển:

$$p(x | y; \mu, \Sigma) = \frac{1}{\sqrt{(2\pi)^n |\Sigma|}} \exp \left(-\frac{1}{2} (x - \mu_y)^T \Sigma^{-1} (x - \mu_y) \right)$$

3.2 Tiêu chí đánh giá

Các chỉ số dựa trên **Confusion Matrix** giúp định lượng chi tiết sai số phân loại: **TP** là số ảnh *Giả* được dự đoán đúng; **TN** là số ảnh *Thật* được dự đoán đúng; **FP** là trường hợp ảnh *Thật* bị dự đoán nhầm thành *Giả* hay báo động nhầm; và **FN** là trường hợp ảnh *Giả* bị dự đoán nhầm thành *Thật* làm bỏ sót ảnh giả. Các chỉ số đánh giá được tham khảo từ tài liệu *scikit-learn metrics*¹.

Accuracy = $\frac{TP + TN}{Total}$	Precision = $\frac{TP}{TP + FP}$	Recall = $\frac{TP}{TP + FN}$
F1-score = $2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$		Đường cong ROC-AUC

- **Accuracy:** Tỷ lệ dự đoán chính xác trên toàn bộ tập dữ liệu huấn luyện và kiểm thử.
- **Precision:** Độ tin cậy của mô hình khi đưa ra cảnh báo một hình ảnh là ảnh giả.
- **Recall:** Khả năng phát hiện và không bỏ sót các hình ảnh đã qua chỉnh sửa tình vi.
- **F1-score & AUC:** Đánh giá sự cân bằng sai số và khả năng phân biệt lớp của mô hình.

¹<https://scikit-learn.org/stable/api/sklearn.metrics.html>

Chapter 4

Kết quả thực nghiệm

4.1 Kết quả huấn luyện




Figure 4.1: Kết quả đánh giá huấn luyện

Phân tích biểu đồ tuning của **Logistic Regression** và **GDA** cho thấy số thành phần PCA là yếu tố then chốt ảnh hưởng đến hiệu năng mô hình.

- **Đối với Logistic Regression:** Độ chính xác tăng khi k tăng từ 400 và đạt đỉnh tại $k = 700$ với Validation Accuracy = 76.91%. Việc tăng số chiều khiến mô hình học phải nhiều, giảm hiệu năng. Các tham số như C hay $class_weight$ chỉ tạo ra thay đổi nhỏ, chứng tỏ dữ liệu đã khá cân bằng và ít nhạy cảm với điều chuẩn.
- **Đối với GDA:** Mô hình tối ưu tại $k = 700$ và $reg_param = 0.1$ với Accuracy = 77.17%. Tương tự như Logistic Regression, sau ngưỡng này hiệu quả giảm nhẹ do các thành phần có phương sai thấp mang lại nhiều nhiễu hơn là thông tin hữu ích.

Kết luận: Cả hai mô hình đều đạt hiệu suất tốt nhất tại $k = 700$, khẳng định đây là điểm cân bằng tối ưu giữa việc giữ lại thông tin đặc trưng và loại bỏ nhiễu dữ liệu.

4.2 Ma trận nhầm lẫn




Figure 4.2: Ma trận nhầm lẫn của hai mô hình

Việc phân tích ma trận nhầm lẫn giúp định lượng chi tiết khả năng nhận diện của mô hình đối với từng lớp dữ liệu cụ thể:

- **Khả năng nhận diện ảnh đã chỉnh sửa:** Cả hai mô hình thể hiện ưu thế vượt trội ở lớp này. GDA đạt **2312** mẫu TP chỉ bỏ sót 311 mẫu FN, trong khi Logistic Regression đạt **2307** mẫu TP bỏ sót 316 mẫu FN. Tỷ lệ FN thấp là minh chứng cho khả năng quét ảnh giả hiệu quả, đáp ứng mục tiêu cốt lõi của bài toán.
- **Khả năng nhận diện ảnh thật:** Điểm hạn chế chung khi cả hai mô hình vẫn còn nhầm lẫn đáng kể. GDA có **1409** mẫu TN, nhầm 1195 mẫu FP, nhỉnh hơn so với Logistic Regression với **1399** mẫu TN, nhầm 1205 mẫu FP.

Kết luận: Hiệu suất phân loại của GDA và Logistic Regression là tương đương. Cả hai đều ưu tiên phát hiện lớp FAKE, chấp nhận tỷ lệ báo động nhầm ở lớp REAL để đảm bảo không bỏ lọt các trường hợp ảnh giả nguy hiểm. Điều này hoàn toàn phù hợp với yêu cầu thực tiễn của hệ thống phát hiện giả mạo hình ảnh.

4.3 Kết quả đánh giá trên tập kiểm thử

Metric	Logistic Regression	GDA
Accuracy	70.9%	71.19%
Precision	0.66	0.66
Recall	0.88	0.88
F1-score	0.75	0.75
ROC-AUC	0.8079	0.8055

Figure 4.3: Bảng so sánh hiệu năng các mô hình trên tập kiểm thử

Dựa trên kết quả thực nghiệm, nhóm đưa ra các nhận định sau về hiệu năng của hai mô hình:

- **Về độ chính xác tổng thể:** GDA đạt Accuracy nhỉnh hơn (**71.19%**) so với Logistic Regression (**70.9%**). Tuy nhiên, mức chênh lệch không đáng kể, cả hai đều có năng lực phân loại tổng quát tương đương trên tập kiểm thử.
- **Về khả năng phát hiện ảnh giả:** Cả hai mô hình đạt chỉ số **Recall** xấp xỉ **0.88**, nhận diện tốt các mẫu ảnh đã qua chỉnh sửa và hạn chế việc bỏ sót các ảnh vi phạm. Chỉ số **Precision** dừng lại ở mức **0.66**, cho thấy mô hình vẫn còn khó khăn trong việc phân biệt giữa ảnh thật và ảnh giả có độ tinh vi cao.
- **Về tính ổn định và khả năng phân biệt:** Logistic Regression thể hiện ưu thế về chỉ số **ROC-AUC** (0.8079 so với 0.8055). Điều này khẳng định Logistic Regression phân biệt giữa hai lớp tốt hơn trên nhiều ngưỡng quyết định khác nhau và có tính ổn định cao hơn khi triển khai thực tế.

Kết luận: GDA có lợi thế về hiệu suất tính toán và độ chính xác chung, trong khi Logistic Regression ưu thế ở khả năng phân biệt lớp. Với bài toán này, nơi ưu tiên chính xác trong xác định các dấu vết chỉnh sửa – cả hai mô hình đều là lựa chọn tiềm năng nhưng cần cải thiện thêm để giảm tỷ lệ báo động nhầm.

4.4 Không gian phân bố dữ liệu và ranh giới quyết định




Figure 4.4: Không gian đặc trưng sau PCA của mô hình Logistic Regression và GDA

- **Đối với Logistic Regression:** Biểu đồ *Logistic 2D Boundary* cho thấy hai lớp REAL và FAKE bị chồng chéo mạnh trong không gian đặc trưng, khiến mô hình gặp khó khăn trong việc phân tách dữ liệu bằng ranh giới tuyến tính. Tuy nhiên, hiện tượng này chỉ phản ánh trên hai thành phần PCA đầu tiên và chưa đại diện hoàn toàn cho hiệu năng thực tế trong không gian 700 chiều.
- **Đối với GDA:** Dữ liệu có xu hướng phân bố theo dạng Gaussian nhiều chiều, phù hợp với giả định của mô hình GDA. Nhờ khai thác thông tin phân phối xác suất, GDA mô tả cấu trúc dữ liệu tốt hơn và đạt Accuracy cao hơn nhẹ so với Logistic Regression. Tuy nhiên, hai lớp vẫn bị chồng lấn đáng kể nên ranh giới quyết định của GDA cũng gần tuyến tính.

Kết luận: Cả hai mô hình đều gặp khó khăn do mức độ chồng chéo lớn giữa hai lớp trong không gian 2D. Tuy nhiên, GDA vẫn cho hiệu quả tốt hơn nhờ khả năng mô hình hóa phân phối dữ liệu.

4.5 Đánh giá chung

- **Về cấu trúc dữ liệu:** Số thành phần PCA ($k \approx 700$) đóng vai trò quyết định đến hiệu năng, vượt trội so với ảnh hưởng của các tham số điều chuẩn. Khẳng định tầm quan trọng của việc tối ưu hóa không gian đặc trưng trong bài toán phân loại ảnh.
- **Về hiệu năng:** GDA ưu thế nhỏ về độ chính xác trên cả tập validation và test. Tuy nhiên, **Logistic Regression** thể hiện khả năng phân biệt lớp ổn định hơn với chỉ số **ROC-AUC** cao hơn và duy trì tỷ lệ bỏ sót ảnh giả **FN** ở mức thấp.
- **Về tính phù hợp:** GDA bị hạn chế do giả định Gaussian không hoàn toàn tương thích với dữ liệu ảnh sau khi giảm chiều. Ngược lại, Logistic Regression cho khả năng tổng quát hóa tốt hơn, không ràng buộc bởi các giả định phân phối khắt khe.

Kết luận cuối cùng: Kết quả hai mô hình khá tương đồng, cho thấy cả Logistic Regression và GDA đều có khả năng nhận diện ảnh giả hiệu quả. Tuy nhiên, mức độ chồng chéo giữa hai lớp cho thấy bài toán vẫn còn nhiều thách thức và cần được cải thiện bằng các phương pháp trích xuất đặc trưng hoặc mô hình mạnh hơn trong tương lai.

Chapter 5

Kết luận và hướng phát triển

5.1 Kết luận

Đề tài tập trung nghiên cứu bài toán phân loại ảnh thật và ảnh chỉnh sửa thông qua việc so sánh hai mô hình học máy là **Logistic Regression** và **Gaussian Discriminant Analysis**. Dữ liệu được xử lý qua các bước trích xuất đặc trưng như Raw Pixel, ELA, FFT, LBP và đặc trưng màu YCbCr, sau đó được chuẩn hóa và giảm chiều bằng PCA nhằm tối ưu hiệu quả huấn luyện.

Kết quả thực nghiệm cho thấy cả hai mô hình đều đạt hiệu suất khá trong bài toán phát hiện ảnh giả. Tuy nhiên, GDA cho kết quả ổn định hơn về độ chính xác tổng thể cũng như khả năng phân loại trên tập kiểm thử. Confusion Matrix và chỉ số ROC-AUC cho thấy cả hai mô hình đều có khả năng phát hiện tốt ảnh đã qua chỉnh sửa, trong đó GDA thể hiện phù hợp hơn với bộ đặc trưng sau quá trình giảm chiều.

5.2 Hạn chế

Dù đạt được những kết quả nhất định, đề tài vẫn tồn tại hạn chế cần khắc phục:

- **Phạm vi dữ liệu:** Tập dữ liệu chủ yếu tập trung vào các dạng chỉnh sửa phổ biến như *splicing* và *retouching*, chưa bao quát các hình thức giả mạo tinh vi từ các mô hình AI hiện đại như GANs hay Diffusion Models.
- **Kiến trúc mô hình:** Việc sử dụng các thuật toán học máy truyền thống làm hạn chế khả năng khai thác các đặc trưng không gian sâu (deep spatial features) so với các kiến trúc Deep Learning tiên tiến.
- **Mất mát thông tin:** Kỹ thuật PCA dù tối ưu về mặt tốc độ huấn luyện nhưng vô tình có thể loại bỏ những thông tin đặc trưng ở mức vi mô, vốn rất quan trọng để phát hiện các dấu vết thao túng nhỏ nhất.

5.3 Hướng phát triển

Để nâng cao hiệu quả và tính ứng dụng, nhóm đề xuất các hướng mở rộng sau:

- **Đa dạng hóa dữ liệu:** Bổ sung và huấn luyện mô hình trên các tập dữ liệu ảnh được tạo bởi AI hiện đại tăng tính thích nghi với các xu hướng giả mạo mới.
- **Tích hợp Deep Learning:** Kết hợp các mạng nơ-ron như *CNN*, *EfficientNet* hoặc *Vision Transformer* với các đặc trưng truyền thống cải thiện độ chính xác tổng thể.
- **Trực quan hóa:** Nghiên cứu các phương pháp *Explainable AI* giải thích lý do mô hình đưa ra quyết định phân loại, từ đó tăng độ minh bạch cho hệ thống phân loại.

—Hết—